

## Metamodeling and data assimilation

### I/ Gaussian process and uncertainty quantification

metamodélisation : on peut créer nos données

(on dispose d'un simulateur ou d'un algo de ML  
qu'on veut régler)

exemple : Bayesian optimization

metamodeling - computer experiments - surrogate modeling

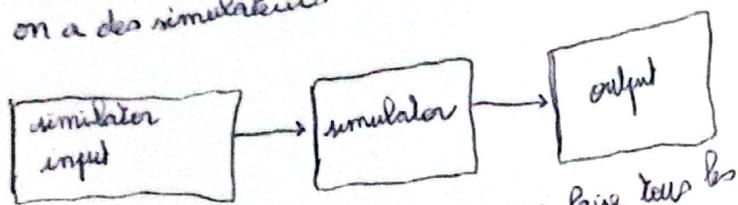
#### exemple 1

on veut créer un nouveau véhicule

on veut faire des nombreux tests

on n'a pas assez de temps

on a des simulateurs



on n'a pas beaucoup de ressources pour faire tous les tests

⇒ on utilise un metamodel

on a 100 simulations

on fait 20 expériences avec le vrai modèle physique

on apprend les metamodels

comme

on fait de nouvelles expériences

on enrichit le metamodel

family de variables aléatoires  $\{Z(x)\}_{x \in X}$

$(\Omega, \mathcal{F}, \mathbb{P})$  espace probabiliste

$Y$ : variable aléatoire réelle

$Y: \Omega \rightarrow \mathbb{R}$

$w \rightarrow Y(w)$

$(Z(x))_{x \in X}$  processus aléatoire

$Z(x): \Omega \rightarrow \mathbb{R}$   
 $w \rightarrow Z(x)(w)$

Trajectoire

$w$  fixé

$X \rightarrow \mathbb{R}$   
 $x \rightarrow Z(x) w$

Exemple 1:

$X = \mathbb{N}$

$(Z(x))_{x \in X}$  bruit blanc

i.e.  $\forall x \neq x'$   $Z(x) \perp \perp Z(x')$

$Z(x)$  a même loi que  $Z(x')$

Exemple 2: mouvement brownien en dim<sup>1</sup>

$X = \mathbb{R}^+$

$$\text{cov}(Z(t), Z(t')) = \min(t, t')$$

Exemple 3

processus aléatoire

exemple 3

processus gaussien

noyer: squared exponential

$$X = \{0, 1\}$$

$$R(x, x') = \text{cov}(Z(x), Z(x')) = e^{-\frac{(x-x')^2}{P^2}}$$

second order RP

$Z$  is a second order RP return  
all the random variables  $Y(x) \in L^2(\Omega)$

$\Rightarrow$  they all have variance

covariance function or kernel

$$R(x, x') = \text{cov}(Y(x), Y(x'))$$

stationnarity

$Y$  is strongly stationary if for all locations

$$x_1, \dots, x_n \in X$$

the law of  $(Y(x_1 + h), \dots, Y(x_n + h))$  does not depend on  $h$

2)  $Y$  is weakly stationary if for all locations  
 $x_1, \dots, x_n \in X$  the first two moments of  
 $(Y(x_1 + h), \dots, Y(x_n + h))$

## processus gaussien

un processus  $(Z(x))$  est gaussien si

$\forall (x_1, \dots, x_n)$  la loi du vecteur  $(Z(x_1), \dots, Z(x_n))$  est gaussienne.

La loi d'un PG dépend de

$m: x \mapsto \mathbb{E}(Z(x))$  moyenne (peut que l'on que)

$R: (\mathbb{X}, \mathbb{X}) \mapsto \mathbb{R}$   $\text{cov}(Z(x), Z(x'))$

$R$  doit être semi définie positive

$\forall x_1, \dots, x_n \in \mathbb{X} \quad \text{cov} \begin{pmatrix} Z(x_1) \\ \vdots \\ Z(x_n) \end{pmatrix}$  est semi définie positive

$$\text{cov} \begin{pmatrix} Z(x_1) \\ \vdots \\ Z(x_n) \end{pmatrix} = \left( \begin{array}{c|c} & i \\ & \vdots \\ \text{cov}(Z(x_i), Z(x_j)) & j \\ \hline & 1 \leq i, j \leq n \end{array} \right)$$

$$= \begin{pmatrix} & i \\ R(x_i, x_j) & j \\ & 1 \leq i, j \leq n \end{pmatrix}$$

$$= R(X, X)$$

$$\text{avec } X = \{x_1, \dots, x_n\}$$

Alors  $\forall X$

$$\forall x \in \mathbb{R}^n$$

$$x^T R(X, X) x \geq 0$$

$$\Leftrightarrow \sum_{1 \leq i, j \leq n} x_i x_j R(x_i, x_j) \geq 0$$

$$Y_0 \sim CP(0, R_0)$$

Ex: Malin  $\frac{5}{2}$

à partir de  $Y_0$ : on peut avoir plusieurs repères

$$Y \sim CP(0, R)$$

donc les repères sont empiriques

$$Y(x) = Y_0(x) + Y_0(-x)$$

$L: f \rightarrow f(x) - f(-x)$  est linéaire

$$Y(-x) = Y_0(-x) - Y_0(x) = -Y(x)$$

### Exercice 3

Montrer que  $Y$  est un BP

soit  $(x_1, \dots, x_n) \in X$

$$\begin{pmatrix} Y(x_1) \\ \vdots \\ Y(x_n) \end{pmatrix} = \begin{pmatrix} Y_0(x_1) & -Y_0(-x_1) \\ \vdots & \vdots \\ Y_0(x_n) & -Y_0(-x_n) \end{pmatrix}$$

$$= \begin{pmatrix} Y_0(x_1) \\ \vdots \\ Y_0(x_n) \end{pmatrix} + \begin{pmatrix} -Y_0(-x_1) \\ \vdots \\ -Y_0(-x_n) \end{pmatrix}$$

vector gaussien      vector gaussien

$$\begin{pmatrix} -x_1 \\ \vdots \\ -x_n \end{pmatrix} \in X \Rightarrow Y \sim CP$$

Rechts für comb linéaire:  $\begin{pmatrix} Y(x_1) \\ \vdots \\ Y(x_n) \end{pmatrix}$  vector gaussien  $\rightarrow$  ce n'est pas vrai

$$\sqrt{(x_1, -x_n)} \in X$$

$$\Rightarrow Y \sim BP \quad L: f \rightarrow f(x) - f(-x) \text{ linéaire}$$

$$L(Y_0) = Y$$

$Y_0$  est un CP

$$\begin{aligned} 2) \quad & \mathbb{E} \left[ \begin{pmatrix} Y(x_1) \\ \vdots \\ Y(x_n) \end{pmatrix} \right] \\ &= \mathbb{E} \left[ \begin{pmatrix} Y_0(x_1) \\ \vdots \\ Y_0(x_n) \end{pmatrix} \right] + \mathbb{E} \left[ \begin{pmatrix} -Y_0(-x_1) \\ \vdots \\ -Y_0(-x_n) \end{pmatrix} \right] \\ &= \mathbb{E} \left[ \begin{pmatrix} Y_0(x_1) \\ \vdots \\ Y_0(x_n) \end{pmatrix} \right] - \mathbb{E} \left[ \begin{pmatrix} Y_0(-x_1) \\ \vdots \\ Y_0(-x_n) \end{pmatrix} \right] \\ &\approx \mathbb{E}[Y] = \mathbb{E}[Y_0(x)] - \mathbb{E}[Y_0(-x)] \\ &\quad \text{car } Y_0 \sim CP(0, R_0) \\ \Rightarrow Y &\text{ est centré} \\ &\quad \stackrel{O-O}{=} \text{ car } Y_0 \sim CP(0, R_0) \\ &R(x, x') = \text{cov}(Y(x), Y(x')) \\ &= \text{cov}(Y_0(x) - Y_0(-x), Y_0(x') - Y_0(-x')) \\ &= \text{cov}(Y_0(x), Y_0(x')) + \text{cov}(Y_0(x), Y_0(-x')) \\ &\quad + \text{cov}(Y_0(-x), Y_0(x')) + \text{cov}(Y_0(-x), Y_0(-x')) \\ &\quad \stackrel{\text{indép.}}{=} + \text{cov}(Y_0(-x), Y_0(x')) + \text{cov}(Y_0(-x), Y_0(-x')) \\ &= R_0(x, x') - R_0(x, -x') - R_0(-x, x') \\ &\quad + R_0(-x, -x') \end{aligned}$$

### Correction

1/ considérons une comb linéaire

$$a_1 Y(x_1) + \dots + a_n Y(x_n) = 0$$

rg:  $U$  est de la normale

$$U = a_1 \cdot Y_0(x_1) + a_1 Y_0(-x_1) + \dots + a_n Y_0(x_n) - a_n Y_0(-x_n)$$

$Y_0$  est un processus gaussien

rg: une comb linéaire extrait de  $Y_0$  aux points

$$x_1, \dots, x_n, -x_1, \dots, -x_n$$

$\Rightarrow U$  est de la normale

## Zerne methode

$$\begin{bmatrix} Y_0(x_1) \\ \vdots \\ Y_0(x_n) \\ Y_0(-x_1) \\ \vdots \\ Y_0(-x_n) \end{bmatrix}$$

ist ein reduz. Gaußian  
in  $\gamma$  ist ein GP

$$\begin{bmatrix} \gamma(x_1) \\ \vdots \\ \gamma(x_n) \end{bmatrix} = \begin{bmatrix} 1 & \dots & 0 & 1 & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 & 0 & 0 & \dots & 0 \\ \vdots & & \ddots & & & \vdots & & & \vdots \\ 0 & & 0 & 1 & & 0 & & & 0 \\ 0 & & 0 & 0 & 1 & & & & 0 \\ \vdots & & & & & \ddots & & & \vdots \\ 0 & & 0 & 0 & 0 & -1 & 0 & & 0 \end{bmatrix} \begin{bmatrix} Y_0(x_1) \\ \vdots \\ Y_0(x_n) \\ Y_0(-x_1) \\ \vdots \\ Y_0(-x_n) \end{bmatrix}$$

-  $\Rightarrow$  reduz. Gaußian

## Exercice 1 : Having the very first regression with derivatives

$$Y \sim GP(0, h)$$

$$Z = \begin{pmatrix} Y(x) \\ Y(x_1) \\ Y'(x_1) \end{pmatrix}$$

GP Regression:  $Y(x) | Y(x_1), \dots, Y(x_n)$

on a des dérivées en  $x_1, \dots, x_n$

on pourraient calculer

$$Y(x) | Y(x_1), \dots, Y(x_n), Y'(x_1), \dots, Y'(x_n)$$

un premier pas est de calculer la forme:

$$\begin{pmatrix} Y(x) \\ Y(x_1) \\ \vdots \\ Y(x_n) \\ Y'(x_1) \\ \vdots \\ Y'(x_n) \end{pmatrix} \text{ et avec } n=3 \begin{pmatrix} Y(x) \\ Y(x_1) \\ Y'(x_1) \end{pmatrix}$$

$\Rightarrow$  ~~Y(x) ~ GP(0, h)~~  $\Rightarrow$  ~~Y'(x) ~ GP(0, h')~~

$$Y \sim GP(0, h) \Rightarrow Y' \sim GP\left(0, \frac{\partial^2 h}{\partial x \partial t}\right)$$

$$E[Z] = \begin{pmatrix} E[Y(x)] \\ E[Y(x_1)] \\ E[Y'(x_1)] \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

$E[Z]$  si  $Z$  est un processus Gaussien

d'application:  $Y \rightarrow \begin{pmatrix} Y(x) \\ Y(x_1) \\ Y'(x_1) \end{pmatrix}$  est linéaire

comme  $Y$  est GP alors  $Z = \begin{pmatrix} Y(x) \\ Y(x_1) \\ Y'(x_1) \end{pmatrix}$  aussi

est un vecteur Gaussien

$$\text{cov}(Z) = \begin{pmatrix} \text{Var}(Y(x)) & & \\ \text{cov}(Y(x), Y(x_1)) & \text{Var}(Y(x_1)) & \\ \text{cov}(Y(x), Y'(x_1)) & \text{cov}(Y(x_1), Y'(x_1)) & \text{Var}(Y'(x_1)) \end{pmatrix}$$

$$\text{Var}(Y(x)) = h(y(x, x))$$

$$\text{cov}(Y(x), Y'(x_1)) = \frac{\partial h(y(x, x_1))}{\partial x} \Big|_{(x, x_1)} = (x, x_1)$$

on a une  
dérivée à la  $x$   $\Rightarrow$  faut donner une  
variable correspondante rapporté à la  $x$

$$\text{Var}(Y'(x_1)) = h \left( \frac{\partial^2 h}{\partial x \partial t} \right) \Big|_{(x, x_1)} = (x_1, x_1)$$

$$\Gamma_X = \begin{pmatrix} \text{Var}(x_1) & \text{cov}(x_1, x_2) & \text{cov}(x_1, x_3) \\ \text{cov}(x_2, x_1) & \text{Var}(x_2) & \text{cov}(x_2, x_3) \\ \text{cov}(x_3, x_1) & \text{cov}(x_3, x_2) & \text{Var}(x_3) \end{pmatrix}$$

### Exercice 3

$$u(t) \frac{\partial u}{\partial t}(x,t) = -d \cdot \frac{\partial^2 u}{\partial x^2}(x,t) = 0$$

$\downarrow$   $u(x,t) = \phi(x)$   
transformation de Fourier

$$u(x,t) = \int_{\mathbb{R}} s(x-y,t) \phi(y) \cdot dy$$

$$s(x,t) = (4\pi d t)^{-\frac{1}{2}} \exp\left(-\frac{x^2}{4dt}\right)$$

on peut considérer  $(\phi(x)) \sim GP(0, R_\phi)$

$R_\phi$  est un processus gaussien centré

+ calculer son moyen

$$L\phi : \mathbb{R} \rightarrow \int s(x-y,t) \phi(y) \cdot dy$$

$L$  est linéaire et  $L\phi = \phi(L)$

$\Rightarrow u$  est un processus gaussien

$$\begin{aligned} E[u(t)] &= E\left[\int_{\mathbb{R}} s(x-y,t) \phi(y) \cdot dy\right] \\ E[u(x,t)] &= \int_{\mathbb{R}} s(x-y,t) \cdot \underbrace{E[\phi(y)]}_{=0} \cdot dy \end{aligned}$$

Fubini  
Tonelli

$= 0$

$$\begin{aligned} \Rightarrow u &\text{ est centré} \\ R_u(x,x') &= \text{cov}\left(u(x,y), u(x',y')\right) \\ &= \text{cov}\left(\int s(x-y,t) \phi(y) \cdot dy, \int s(x'-y',t) \phi(y') \cdot dy'\right) \\ &= \int \int s(x-y,t) \cdot \text{cov}(\phi(y), \phi(y')) \cdot s(x'-y',t) \text{cov}(\phi(y'), \phi(y')) \cdot dy \cdot dy' \\ &= \iint_{\mathbb{R}^2} s(x-y,t) s(x'-y',t) R_\phi(y, y') \cdot dy \cdot dy' \end{aligned}$$

### Exercice 1

Si  $R(x, x') \text{ nég} = \text{cor}(Y(x), Y(x'))$  alors  $R$  est prod  
soient  $\alpha_1, \alpha_2, \dots, \alpha_n \in \mathbb{R}$ ;  $x_1, \dots, x_n \in \mathbb{X}$

$$\sum_{i,j} \alpha_i \alpha_j R(x_i, x_j) = \sum_{i,j} \alpha_i \alpha_j \text{cor}(Y(x_i), Y(x_j)) \\ = \text{cor}\left(\underbrace{\sum_i \alpha_i Y(x_i)}_U, \underbrace{\sum_j \alpha_j Y(x_j)}_V\right)$$

bilinearité de

la covariance

$$= \text{cor}(U, V) \\ = \text{Var}\left(\sum_i \alpha_i Y(x_i)\right) \geq 0$$

### Remarque

$$\text{Si } Y \text{ est centré : } R(x, x') = \mathbb{E}[Y(x) Y(x')] \\ = \langle Y(x), Y(x') \rangle_{L^2(\mathbb{P})} \\ = \langle \phi(x), \phi(x') \rangle_H$$

avec  $\phi: x \mapsto Y(x)$  et  $H: L^2(\mathbb{P})$ : espace de Hilbert

### propriétés

$R$  négau  $\Rightarrow c^2 R$  négau  $\forall c \in \mathbb{R}$

$$R_1 \oplus R_2 \left( \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}, \begin{pmatrix} x'_1 \\ x'_2 \end{pmatrix} \right) = R_1(x_1, x'_1) + R_2(x_2, x'_2)$$

$$R_1 \otimes R_2 \left( \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}, \begin{pmatrix} x'_1 \\ x'_2 \end{pmatrix} \right) = R_1(x_1, x'_1) R_2(x_2, x'_2)$$

### RKHS et processus

def: noyau :  
 $(R(x_i, x_j))$  est à prod  
(fonction semi définit)

Exercice 2 : transformation et processus  
 $R \leftrightarrow Y$        $R(x, x') = \text{cor}(Y(x), Y(x'))$

$$c^2 R \leftrightarrow Z = cY$$

$$c^2 R(x, x') = \text{cor}(cY(x), cY(x'))$$

$Z$  est un GP

car  $g \mapsto cg$  est linéaire  
et  $Y$  est un GP

$u \mid f: \mathbb{U} \rightarrow \mathbb{V}$        $R$  négau sur  $\mathbb{X}$

$$R_f(x, x') = R(f(x), f(x'))$$

$$R(f(x), f(x')) = \text{cor}(Y(f(x)), Y(f(x')))$$

$$Z(x) = Y(f(x))$$

$$\text{cor}(Z(x), Z(x')) = \text{cor}(Y(f(x)), Y(f(x'))) \\ = \text{cor}(Y(u)) \\ = R(u, u')$$

$$\text{avec } u = f(x) \quad u' = f(x')$$

$$= R(f(x), f(x')) \\ = R_f(x, x')$$

$$\text{et } Y \rightarrow Y(L^2(\mathbb{P})) \text{ et } x \mapsto Y(f(x))$$

est linéaire par rapport à  $Y$

$\Rightarrow Z$  est un GP

$f$

$$f: \mathbb{X} \rightarrow \mathbb{U}$$

$$R_f(x, x') = R(f(x), f(x'))$$

autre preuve

Soit une CP extraite de  $Z$  en  $x_1, \dots, x_n$

$$\begin{aligned} & \alpha_1 Z(x_1) + \dots + \alpha_n Z(x_n) \\ &= \alpha_1 Y(f(x_1)) + \dots + \alpha_n Y(f(x_n)) \end{aligned}$$

c'est une CP extraite de  $Y$  aux points

$$u_1, \dots, u_n$$

or  $Y$  est un CP

$\Rightarrow Z$  est un CP

$$\overline{Y_1 \amalg Y_2} \quad R_1 + R_2 \leftrightarrow Y_1 + Y_2 = Z$$

$Z$  est un CP

$$\overline{Y_1 \amalg Y_2} \quad Z = Y_1 Y_2$$

Induction théorique que  $Z$  est centré

$$\text{Si calculer } R_Z(x, x') = \mathbb{E}[Z(x)Z(x')] \quad ]$$

$$\begin{aligned} \mathbb{E}[Z] &= \mathbb{E}[Y_1 Y_2] = \mathbb{E}[Y_1] \mathbb{E}[Y_2] \\ &= 0 \end{aligned}$$

$$\begin{aligned} R_Z(x, x') &= \text{cov}(Z(x), Z(x')) \\ &= \mathbb{E}[Z(x)Z(x')] \\ &= \mathbb{E}[Y_1(x)Y_1(x')Y_2(x)Y_2(x')] \\ &= \mathbb{E}[Y_1(x)Y_1(x')]\cdot\mathbb{E}[Y_2(x)Y_2(x')] \\ &= R_1(x, x') \cdot R_2(x, x') \end{aligned}$$

⚠  $Z$  n'est pas un CP

si le PC est stationnaire en 12 alors

$$R(x, x') = c(x - x')$$

$$= c(R)$$

Bachman's theorem :

The kernel of a real valued stationary GP on  $\mathbb{R}^d$   
is the Fourier transform of a probability distribution

$$R(x, x') = \int_{\mathbb{R}^d} \cos(2\pi \langle x - x', r \rangle) d\rho(r)$$

Exercise 6 : proof of the direct sense

1)  $\forall g(x, x') \mapsto \cos(2\pi \langle x - x', r \rangle)$  est semi definite  
positive

soit  $(x_1, \dots, x_d) \in \mathbb{R}^d$

$$\sum_{k=1}^d \sum_{j=1}^d \alpha_i \alpha_j R(x_k, x_j)$$

$$= \sum_{1 \leq k < j \leq d} \alpha_k \alpha_j \cos(2\pi \langle x_k - x_j, r \rangle)$$

or  $\cos(2\pi \langle x_k - x_j, r \rangle) = \operatorname{Re}(e^{i \cdot 2\pi \langle x_k - x_j, r \rangle})$

$$= \sum_{k,j} \alpha_k \alpha_j \operatorname{Re}(e^{i \cdot 2\pi \langle x_k, r \rangle} \cdot e^{-i \cdot 2\pi \langle x_j, r \rangle})$$

= ~~Re~~ ~~Re~~ ~~Re~~ ~~Re~~ ~~Re~~ ~~Re~~

$$= \operatorname{Re} \left( \sum_k \alpha_k \operatorname{Re}(e^{i \cdot 2\pi \langle x_k, r \rangle}) + \sum_j \alpha_j \operatorname{Re}(e^{-i \cdot 2\pi \langle x_j, r \rangle}) \right)$$

$$= \operatorname{Re}(\alpha \bar{\alpha}) = \operatorname{Re}(|\alpha|^2) = |\alpha|^2 \geq 0$$

$$2) \text{ En déduire que } R: (x, x') \mapsto \int \cos(2\pi \langle x - x', r \rangle) d\rho(r)$$

est un noyau

meilleur  
méthode

$$\begin{aligned} \text{Soient } \alpha_1, \dots, \alpha_d \in \mathbb{R}^d \\ \sum_{1 \leq i, j \leq d} \alpha_i \alpha_j \cos(2\pi \langle x_i - x_j, r \rangle) \cdot d\rho(r) \\ = \underbrace{\sum_{1 \leq i, j \leq d} \alpha_i \alpha_j}_{\geq 0} \cos(2\pi \langle x_i - x_j, r \rangle) \cdot d\rho(r) \end{aligned}$$

Exercise 7 : the square exp kernel on a Hilbert space  
 $\{1, \langle \cdot, \cdot \rangle\}$  called  $R(x, x') = e^{-\|x - x'\|^2}$

$$\begin{aligned} 1) R(x, x') &= e^{-\langle x - x', x - x' \rangle} \\ &= e^{-\|x\|^2 - \|x'\|^2 + 2 \langle x, x' \rangle} \\ &= \underbrace{e^{-\|x\|^2}}_{\geq 0} \cdot \underbrace{e^{-\|x'\|^2}}_{\geq 0} \cdot \underbrace{e^{2 \langle x, x' \rangle}}_{\geq 0} \\ &= g(x) g(x') e^{2 \langle x, x' \rangle} \end{aligned}$$

$$2) R_2(x, x') = g(x) g(x')$$

$R_2$  est un noyau

$$\sum_{ij} \alpha_i \alpha_j R_2(x_i, x_j) = \sum_{ij} \alpha_i \alpha_j g(x_i) \cdot g(x_j)$$

$$= \sum_i \alpha_i g(x_i) \cdot \sum_j \alpha_j g(x_j) \geq 0$$

$\Rightarrow R_2$  noyau

3)  $\forall R_0$  un noyau  $\forall$   $e^{R_0}$  noyau

$$R_0(x_i, x_j)$$

$$\sum_{ij} \alpha_i \alpha_j e^{R_0(x_i, x_j)}$$

$$\sum_{ij} \alpha_i \alpha_j e^{R_0(x_i, x_j)} = \sum_{ij} \exp(R_0(x_i, x_j)) \exp(R_0(x_j, x_i))$$

$$\sum_{ij} \alpha_i \alpha_j \sum_{n=0}^{+\infty} \frac{(R_0(x_i, x_j))^n}{n!}$$

$$\sum_{n=0}^{+\infty} \sum_{ij} \frac{\alpha_i \alpha_j (R_0(x_i, x_j))^n}{n!} \rightarrow \geq 0$$

$R_0$  noyau  $\Rightarrow R_0''(x_i, x_j)$

limit of kernels

Rappels vecteurs gaussiens

$$\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \Gamma\right)$$

$$\Gamma = \begin{pmatrix} \text{cov}(x_i, x_j) \end{pmatrix}_{1 \leq i, j \leq 2}$$

$X_2 | X_1 = x_1$  suit une loi normale

$\rightarrow \mathbb{E}[X_2 | X_1 = x_1] \rightarrow$  est linéaire

$\text{Var}(X_2 | X_1 = x_1) \rightarrow$  constante

Démonstration dans le cas  $X_1, X_2$  centrés

$X_1$  et  $X_2$  var

$$\mathbb{E}[X_1] = \mathbb{E}[x_1] = 0$$

$$\underline{\text{calculons}} \quad \mathbb{E}_L(X_2 | X_1) = \alpha + \beta x_1$$

meilleure approximation de  $X_2$  comme fonction affine de  $X_1$  au sens L2

Le produit scalaire dans  $L^2$  est

$$\langle u, v \rangle = \mathbb{E}[u \cdot v]$$

$$\text{Mq } \mathbb{E}_L(X_2 | X_1) = \frac{\text{cov}(X_1, X_2)}{\text{Var}(X_1)} \cdot X_1$$

$$\text{cov}(u, v) = \mathbb{E}[(u - \mathbb{E}(u))(v - \mathbb{E}(v))]$$

$$\text{Var}(u) = \text{cov}(u, u)$$

$$\text{cor}(u, v) = \text{cov}(X_1, X_2)$$

$$\begin{array}{c} \text{X}_2 \\ \downarrow \\ \varepsilon = X_2 - (\alpha + \beta X_1) \\ \rightarrow \mathbb{E}_L(X_2 + X_1) = \alpha + \beta X_1 \end{array}$$

$$\text{Var}(X_1, X_2)$$

La variable aléatoire constante

$$\varepsilon \perp \text{Vect}(u, X_1) \Leftrightarrow \begin{cases} \varepsilon \perp u \\ \varepsilon \perp X_1 \end{cases}$$

$$\Leftrightarrow \langle \varepsilon, X_1 \rangle = 0 \text{ et } \langle \varepsilon, u \rangle = 0$$

$$\Leftrightarrow \mathbb{E}[\varepsilon X_1] = \mathbb{E}[\varepsilon u] = X_2 - (\alpha + \beta X_1)$$

$$u \perp \text{Vect}(X_1) \quad \mathbb{E}[(X_2 - (\alpha + \beta X_1)) \cdot u] = 0$$

$$\langle \varepsilon, u \rangle = 0 \Leftrightarrow \mathbb{E}[(X_2 - (\alpha + \beta X_1)) \cdot u] = 0$$

$$\Leftrightarrow \mathbb{E}[X_2] - \alpha - \mathbb{E}[X_1] = 0$$

$$\Leftrightarrow \alpha = 0$$

$$\varepsilon \perp X_1$$

$$\langle \varepsilon, X_1 \rangle \Leftrightarrow \mathbb{E}[(X_2 - \beta X_1) \cdot X_1] = 0$$

$$\Leftrightarrow \mathbb{E}[X_1 X_2] - \beta \mathbb{E}[X_1^2] = 0$$

$$\text{REFLEXION} \quad \beta = \frac{\mathbb{E}[X_1 X_2]}{\mathbb{E}[X_1^2]} = \frac{\text{cov}(X_1, X_2)}{\text{Var}(X_1)}$$

En fait on a ici que

$$\mathbb{E}_L(X_2 | X_1) = \underbrace{\mathbb{E}(X_2 | X_1)}$$

projec L de  $X_2$  sur toutes les fonctions de  $X_1$  de carré intégrable

i)  $\varepsilon \perp X_1$

ii)  $(\begin{pmatrix} \varepsilon \\ X_1 \end{pmatrix})$  est un vecteur gaussien

$$\begin{pmatrix} \varepsilon \\ X_2 - \beta X_1 \\ X_1 \end{pmatrix} = \begin{pmatrix} -\beta & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} \varepsilon \\ X_1 \end{pmatrix}$$

de i) et ii)

$$\text{cov}(\varepsilon, X_1) = \begin{pmatrix} \text{Var}(\varepsilon) & 0 \\ 0 & \text{Var}(X_1) \end{pmatrix}$$

orthogonalité

$\Rightarrow \varepsilon$  et  $X_1$  sont indépendants ?

$$\mathbb{P}\left(\begin{pmatrix} \varepsilon \\ X_1 \end{pmatrix} \in A\right) = \frac{1}{2\pi |\Gamma|} e^{-\frac{1}{2}(\varepsilon - z_1)^\top \Gamma^{-1} (\varepsilon - z_1)}$$

$$= \frac{1}{2\pi |\Gamma|} e^{-\frac{1}{2} \frac{\varepsilon^2}{\text{Var}(\varepsilon)}} e^{-\frac{1}{2} \frac{z_1^2}{\text{Var}(X_1)}}$$

équation

$$\text{aussi } f_{(x_1)}\left(\begin{pmatrix} \varepsilon \\ x_1 \end{pmatrix}\right) = f_\varepsilon(\varepsilon) + f_{X_1}(x_1)$$

$\Rightarrow \varepsilon \perp\!\!\!\perp X_1$

$\Rightarrow \varepsilon \perp\!\!\!\perp g(x_1)$  pour toute fonction g

$\Rightarrow \mathbb{E}_L(x_2 | x_1) = \text{proj 1 de } X_2 \text{ sur } L^2(x_1)$

$\Rightarrow \mathbb{E}_L(x_2 | x_1) = \mathbb{E}[x_2] x_1$

b/ Mq que  $X_2 | X_1$  est une loi normale

$$X_2 = \varepsilon + \beta X_1$$

sachant que  $X_1 = x_1$  et  $\varepsilon \perp\!\!\!\perp X_1$

$$X_2 \stackrel{\text{loi}}{=} \varepsilon + \beta x_1$$

de la <sup>normale</sup> loi ~~normale~~ car  $\varepsilon = X_2 - (\alpha + \beta X_1)$

combi linéaire de  $X_1$  et  $X_2$

$\Rightarrow X_2 | X_1 = x_1$  est de loi normale

comme  $\varepsilon \sim N(P_\varepsilon, \sigma_\varepsilon^2)$

$X_2 | X_1 = x_1 \sim N(P_\varepsilon + \beta x_1, \sigma_\varepsilon^2)$

$$P_\varepsilon = \mathbb{E}[\varepsilon] = \mathbb{E}[X_2 - \beta X_1 - \alpha]$$

$$= \underbrace{\mathbb{E}[X_2]}_{=0} - \beta \underbrace{\mathbb{E}[X_1]}_{=0} - \frac{\alpha}{\sigma_\varepsilon^2} = 0$$

$$\mathbb{E}[X_2 | X_1 = x_1] = \beta x_1 = \frac{\text{cov}(X_1, X_2)}{\text{var}(X_1)}$$

$$\sigma_\varepsilon^2 = \text{var}(\varepsilon) = \mathbb{E}[\varepsilon^2]$$

$$\mathbb{E}[\varepsilon^2] = 0$$

$$= \|\varepsilon\|^2$$

$$= \|X_2\|^2 - \|\mathbb{E}_L(X_2 | X_1)\|^2$$

pythagore

$$= \text{var}(X_2) - \beta^2 \text{var}(x_1)$$

$$= \text{var}(X_2) - \left( \frac{\text{cov}(X_1, X_2)}{\text{var}(X_1)} \right)^2 \text{var}(X_1)$$

$$= \text{var}(X_2) - \frac{\text{cov}(X_1, X_2)^2}{\text{var}(X_1)}$$

$$\text{var}(X_2 | X_1 = x_1) = \text{var}(X_2) - \frac{\text{cov}(X_1, X_2)^2}{\text{var}(X_1)}$$

en général

$$\begin{pmatrix} V \\ W \end{pmatrix} \# \sim N \left( \begin{pmatrix} P_V \\ P_W \end{pmatrix}, \begin{pmatrix} \Gamma_V & | & \Gamma_{V,W} \\ - & \Gamma_{W,V} & | & \Gamma_W \end{pmatrix} \right)$$

$$= \Gamma_{V,W}$$

$V \neq W = w$  et un vecteur gaussien

$$\mathbb{E}(V | W = w) = P_V + \Gamma_{V,W} \cdot \Gamma_W^{-1} (w - P_W)$$

$$\text{cov}(V | W = w) = \Gamma_V + \Gamma_{V,W} \cdot \Gamma_W^{-1} \cdot \Gamma_{W,V}$$

en particulier

$$V = X_2 \sim N(0, \text{var}(X_2))$$

$$W = X_1 \sim N(0, \text{var}(X_1))$$

$$\begin{pmatrix} V \\ W \end{pmatrix} = \begin{pmatrix} X_2 \\ X_1 \end{pmatrix} \sim N \left( \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \text{var}(X_2) & \text{cov}(X_2, X_1) \\ \text{cov}(X_1, X_2) & \text{var}(X_1) \end{pmatrix} \right)$$

$$\frac{f_{me}}{ze} \times \frac{ze}{he} \times \frac{he}{le} =$$

$$\frac{f_{me}}{he} \times \frac{he}{le} = \frac{f_{me}}{le}$$

### Exercice 11

But : montrer que si  $\gamma \sim GP(m, R)$   
 moyenne moyen

$$\text{alors } \forall i \quad \gamma(x_i) = y_i, \dots, \gamma(x_n) = y_n$$

est un GP  $(m_c, R_c)$  avec

$$m_c(x) = m(x) + R(x, X) \underbrace{R(X, X)^{-1}}_{n \times n} \underbrace{(y - m(x))}_{n \times 1}$$

$$R_c(x, X) = (R(x, x_1), \dots, R(x, x_n))$$

vecteur  $1 \times n$

1)  $V = Y(x) \rightarrow$  c'est un point

$$V \quad W = \begin{pmatrix} Y(x_1) \\ \vdots \\ Y(x_n) \end{pmatrix}$$

$$\text{Mq } U = \begin{pmatrix} V \\ W \end{pmatrix} \sim N\left(\begin{pmatrix} \mu_V \\ \mu_W \end{pmatrix}, \begin{pmatrix} \Gamma_V & \Gamma_{V,W} \\ \Gamma_{W,V} & \Gamma_W \end{pmatrix}\right) ?$$

W est un vecteur gaussien car Y est un PG

Y est aussi un vecteur gaussien

$$V \sim N(m(x), R_x) \sim N(m(x), R(x, x))$$

$$W \sim N\left(\begin{pmatrix} m(x_1) \\ \vdots \\ m(x_n) \end{pmatrix}, \begin{pmatrix} \text{Var}(x_1) & \text{cov}(x_1, x_2) \\ \vdots & \ddots \\ \text{cov}(x_n, x_1) & \text{Var}(x_n) \end{pmatrix}\right)$$

$$\sim N\left(\begin{pmatrix} m(x_1) \\ \vdots \\ m(x_n) \end{pmatrix}, R_c(x, X)\right)$$

$$U \sim N\left(\begin{pmatrix} m(x) \\ m(x_1) \\ \vdots \\ m(x_n) \end{pmatrix}, \begin{pmatrix} R(x, x) & R(x, x_1) & \cdots & R(x, x_n) \\ R(x_1, x) & R(x_1, x_1) & \cdots & R(x_1, x_n) \\ \vdots & \vdots & \ddots & \vdots \\ R(x_n, x) & R(x_n, x_1) & \cdots & R(x_n, x_n) \end{pmatrix}\right)$$

Mq U est un vecteur gaussien ?

car  $\Rightarrow (x, x_1, \dots, x_n)$  est un ensemble de  $(n+1)$  points + Y est un GP  $\Rightarrow U = \begin{pmatrix} Y(x) \\ Y(x_1) \\ \vdots \\ Y(x_n) \end{pmatrix}$  est gaussien

$\sqrt{|W|} = w$  est un vecteur gaussien  
 $E[\sqrt{|W|} = w] = m(x) + R(x, X) \cdot R(X, X)^{-1} (y - m(x))$

$$\text{Var}[\sqrt{|W|} = w] = R(x, x) - R(x, X) R(X, X)^{-1} R(X, x)$$

$$2) \sqrt{|W|} = \sqrt{\sum_{i=1}^n y_i^2} \sim \sqrt{E[Y(x_i)^2] - E[Y(x_i)]^2}$$

$$m_c(x_i) = E[Y(x_i) | Y(x_1) = y_1, \dots, Y(x_n) = y_n]$$

$$= E[y_i] \quad \begin{matrix} \downarrow \\ \text{constante} \end{matrix}$$

$$= y_i$$

$$R_c(x_i, x) = \text{cov}(Y(x_i), Y(x))$$

$$Y(x_1) = y_1, \dots, Y(x_n) = y_n$$

$$= \text{cov}(y_i, Y(x)) \quad \begin{matrix} \downarrow \\ \text{deterministe} \end{matrix}$$

$$= 0$$



On ne peut pas dire que  $U$  et  $Y$  sont gaussiens  
 alors  $\begin{pmatrix} U \\ Y \end{pmatrix}$  est gaussien (ceci est vrai si  $U$  et  $Y$  sont indépendantes)

ème méthode

$$m_c(x_i) = m(x_i) + \underbrace{h(x_i, X) R(X, X)^{-1}}_v \begin{pmatrix} y_{i+1} - m(x_i) \\ y_n - m(x_n) \end{pmatrix}$$

3/ Intervalle de prédiction pour une va

$$h(x_i, X) R(X, X)^{-1} = v$$

$$\begin{aligned} h(x_i, X) &= v \times R(X, X) \\ &= v \times \begin{pmatrix} R(x_i, X) \\ R(x_n, X) \end{pmatrix} \end{aligned}$$

$$v = (0, 0, \dots, 1, 0, \dots, 0)$$

$\uparrow$   
ième colonne

$$\begin{aligned} m_c(x_i) &= m(x_i) + y_i - m(x_i) \\ &= y_i \end{aligned}$$

$Z \sim N(P_Z, \sigma_Z^2)$

$$P_Z \pm 2\sigma_Z \text{ à } 95\%$$

$$P(Z \in [P_Z - 2\sigma_Z, P_Z + 2\sigma_Z]) \approx 95\%$$

$$q_{N(0,1)}(0,5\%) \approx q_{N(0,1)}(0,5\%)$$

ici appliquée à la loi de  $Y(x) | Y(x_i) = y_i$  à la 1ère n

$$m_c(x) + 2\sqrt{h_c(x, x)}$$

$$R_c(x, x) = R(x_i, x) \cancel{\oplus} R(x_i, X) \cdot R(X, X)^{-1} \cdot R(X, x)$$

$$h(x_i, X) \cdot R(X, X)^{-1} = v$$

$$h(x_i, X) = v \cdot R(X, X)$$

~~100% de  
100%~~

$$v = (0, \dots, 0, 1, 0, \dots, 0)$$

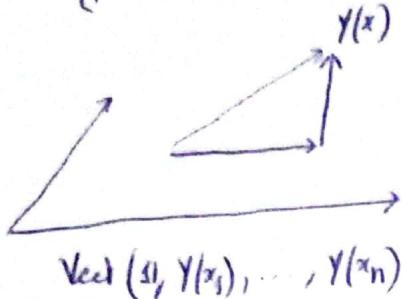
$\uparrow$   
ième position

$$h_c(x_i, x) = 0$$

$\hat{y}$  unbiased

$$\hat{y}(x) = w_0(x) + w_1(x) Y(x_1) + \dots + w_n(x) Y(x_n)$$

$\min \mathbb{E}[(Y(x) - \hat{y}(x))^2] \text{ under } \mathbb{E}[\hat{y}(x)] = \mathbb{E}[Y(x)]$



$$\hat{y}(x) = \mathbb{E}_L(Y(x) | Y(x_1), \dots, Y(x_n))$$

$$\begin{aligned} \text{if } Y \text{ is un PE, alors } \mathbb{E}_L(Y(x) | Y(x_1), \dots, Y(x_n)) \\ = \mathbb{E}(Y(x) | Y(x_1), \dots, Y(x_n)) \end{aligned}$$

$$Y(x) = m(x) + Z(x)$$

$$m(x) = \beta_0 f_0(x) + \dots + \beta_p f_p(x)$$

$Z$  is a centered GP with kernel  $K(x, y; \theta)$

## Observations bruitées et filtrage

$$y_i = \gamma(x_i) + \varepsilon_i \quad i = 1 \dots n$$

✓  
 CP( $m, h$ )      bruit  
 $\varepsilon_1, \dots, \varepsilon_n$  indép  
 $\varepsilon_i \sim N(0, \varepsilon_i^2)$

On suppose de plus que  $\varepsilon_1, \dots, \varepsilon_n$  indép de  $\gamma$

On veut alors calculer la loi de

$$V = \begin{bmatrix} \gamma(x) \\ \gamma(x_1) + \varepsilon_1 \\ \vdots \\ \gamma(x_n) + \varepsilon_n \end{bmatrix} \sim \mathcal{N}\left(\begin{bmatrix} \gamma(x) \\ \gamma(x_1) \\ \vdots \\ \gamma(x_n) \end{bmatrix}, \begin{bmatrix} R(x, x) & R(x, x_1) & \cdots & R(x, x_n) \\ R(x_1, x) & R(x_1, x_1) & \cdots & R(x_1, x_n) \\ \vdots & \vdots & \ddots & \vdots \\ R(x_n, x) & R(x_n, x_1) & \cdots & R(x_n, x_n) \end{bmatrix}\right)$$

signal original      observations non bruitées  
 non bruité

Exercice 19  
Montrer que  $V$  est un vecteur gaussien

Calculer  $\mathbb{E}[V]$  et  $\text{cov}(V)$

Considérons une combinaison linéaire

$$c_0 \gamma(x) + c_1 \gamma(x_1) + c_2 \varepsilon_1 + \dots + c_n \gamma(x_n) + c_n \varepsilon_n$$

~~$\gamma(x) + \gamma(x_1) + \dots + \gamma(x_n) + \varepsilon_1 + \dots + \varepsilon_n$  sont des~~  
~~réalisations de  $\gamma$  et  $\varepsilon_1, \dots, \varepsilon_n$  de loi normale~~  
~~car  $\gamma$  est un CP~~

~~→ combinaison linéaire +  $\varepsilon_1, \dots, \varepsilon_n$  de loi normale + indép~~  
~~de la comb. linéaire~~  
~~→  $c_0 \gamma(x) + c_1 \varepsilon_1 + \dots + c_n \varepsilon_n$  de loi normale~~  
~~→ vecteur réel à coefficients de loi normale~~

$c_1$  et  $c_2$  indép  
 $\Rightarrow c_1 + c_2$  de loi normale  
 $\Rightarrow V$  est Gaussien

$$\mathbb{E}[V] = \begin{bmatrix} \mathbb{E}[\gamma(x)] \\ \mathbb{E}[\gamma(x_1) + \varepsilon_1] \\ \vdots \\ \mathbb{E}[\gamma(x_n) + \varepsilon_n] \end{bmatrix} = \begin{bmatrix} m(x) \\ \frac{m(x_1) + \varepsilon_1}{m(x_1)} \\ \vdots \\ \frac{m(x_n) + \varepsilon_n}{m(x_n)} \end{bmatrix} = m(x)$$

$$\text{cov}(V) = \text{cov}(X, X) = R(x, x)$$

$$\text{cov}(V) = \begin{bmatrix} \text{var}(\gamma(x_1) + \varepsilon_1) \\ \text{cov}((\gamma(x_2) + \varepsilon_2), (\gamma(x_1) + \varepsilon_1)) \\ \vdots \\ \text{var}(\gamma(x_n) + \varepsilon_n) \end{bmatrix}$$

$$\text{var}(\gamma(x_j) + \varepsilon_j) = \text{var}(\gamma(x_j)) + \text{var}(\varepsilon_j)$$

$$\text{var } \varepsilon_j \perp\!\!\!\perp \gamma = R(x_j, x_j) + \varepsilon_j^2$$

$$\text{cov}(\gamma(x_i) + \varepsilon_i, \gamma(x_j) + \varepsilon_j)$$

$$= \text{cov}(\gamma(x_i), \gamma(x_j)) + \text{cov}(\varepsilon_i, \varepsilon_j) + \text{cov}(\gamma(x_i), \varepsilon_j)$$

$$+ \text{cov}(\varepsilon_i, \gamma(x_j))$$

$$= R(x_i, x_j)$$

$$\text{cov}(V) = \begin{bmatrix} R(x_1, x_1) + \varepsilon_1^2 & R(x_1, x_2) & \cdots & R(x_1, x_n) \\ R(x_2, x_1) & R(x_2, x_2) & \cdots & R(x_2, x_n) \\ \vdots & \vdots & \ddots & \vdots \\ R(x_n, x_1) & R(x_n, x_2) & \cdots & R(x_n, x_n) + \varepsilon_n^2 \end{bmatrix}$$

$$\text{cov}(V) = \begin{bmatrix} R(x, x) & R(x, x_1) & \cdots & R(x, x_n) \\ R(x_1, x) & R(x_1, x_1) & \cdots & R(x_1, x_n) \\ \vdots & \vdots & \ddots & \vdots \\ R(x_n, x) & R(x_n, x_1) & \cdots & R(x_n, x_n) \end{bmatrix} \text{cov}(W)$$

$$R(x, x) + \Delta$$

$$\Delta = \begin{pmatrix} \varepsilon_1^2 & & & \\ & \ddots & & \\ & & \ddots & \\ & & & \varepsilon_n^2 \end{pmatrix}$$

### Exercise 3

$$Y \sim CP(0, R)$$

$$R(x_i)$$

$$\text{cov}(Y(x), Y'(x_i))$$

$$= \frac{\partial}{\partial x} R(x_i) \Big|_{(x_i, 1)} = (x_i, x_i)$$

$$U = \begin{bmatrix} Y(x) \\ Y'(x_i) \end{bmatrix} \sim N \left( \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} R(x, x) & \frac{\partial R(x, x)}{\partial x} \Big|_{(x, 1)} = (x, x) \\ \frac{\partial R(x, x)}{\partial x} \Big|_{(x, 1)} = (x, x) & R(x_i, x_i) \end{bmatrix} \right)$$

$$E[Y(x) \mid Y'(x_i) = d_1] = 0 + R(x, x) \cdot \frac{\partial R(x, x)}{\partial x} \Big|_{(x, 1)} (x, x) \cdot \frac{\partial^2 R}{\partial x \partial x} \Big|_{(x_i, x_i)} (x_i, x_i) \cdot \underbrace{(Y'(x_i) - 0)}_{= d_1}$$

$$\text{Var}[Y(x) \mid Y'(x_i) = d_1] = R(x, x) - \frac{\partial R(x, x)}{\partial x} \Big|_{(x, 1)} (x, x) \cdot \frac{\partial^2 R}{\partial x \partial x} \Big|_{(x_i, x_i)} (x_i, x_i) \cdot \frac{\partial R}{\partial x} \Big|_{(x_i, x_i)} (x_i, x_i)$$

$$= R(x, x) - \left( \frac{\partial R(x, x)}{\partial x} \Big|_{(x, 1)} (x, x) \right)^2 \cdot \frac{\partial^2 R}{\partial x \partial x} \Big|_{(x_i, x_i)} (x_i, x_i)$$

Objectif : chercher le min d'une fonction  $f$

$$f: \mathbb{R}^P \rightarrow \mathbb{R}$$

Contrainte : l'évaluation de  $f$  est coûteuse

$$\text{Soit } X = (x_1, \dots, x_n) \quad x_i \in \mathbb{R}^P$$

$$\tilde{Y} = (y_1 = f(x_1), \dots, y_n = f(x_n))$$

$$\{(Y(x); x \in X \subset \mathbb{R}^P\} \sim GP(\mu, R)$$

$$\mathbb{E}[Y(x)] = \mu$$

$$\text{cov}(Y(x), Y(x')) = R(x, x')$$

On définit

$$\text{soit } x = (x_1, \dots, x_n) \quad x_i \in \mathbb{R}^P$$

$$Y_c(x) = \{Y(x) \mid Y(x) = \tilde{Y}, x \in X\} \sim GP(\mu_c(x), R_c(x, x'))$$

$$\mu_c(x) = \mu(x) - R(x, x') R^{-1} Y$$

$$R_c(x, x')$$

$$\hat{\mu}_{\min} = \min(y_1, \dots, y_n) \quad \hat{Y} = \min(\tilde{Y})$$

$$\{(P_{\min} - Y_c(x))_+, x \in X\}$$

$$\varepsilon_i: X \rightarrow \mathbb{R}$$

$$x \mapsto \mathbb{E}(P_{\min} - Y_c(x))_+$$

$$x_{\text{new}} = \underset{x \in X}{\operatorname{argmax}} \varepsilon_i(x)$$

2ème étape

$$X_2 = (x_1, \dots, x_n, x_{\text{new}})$$

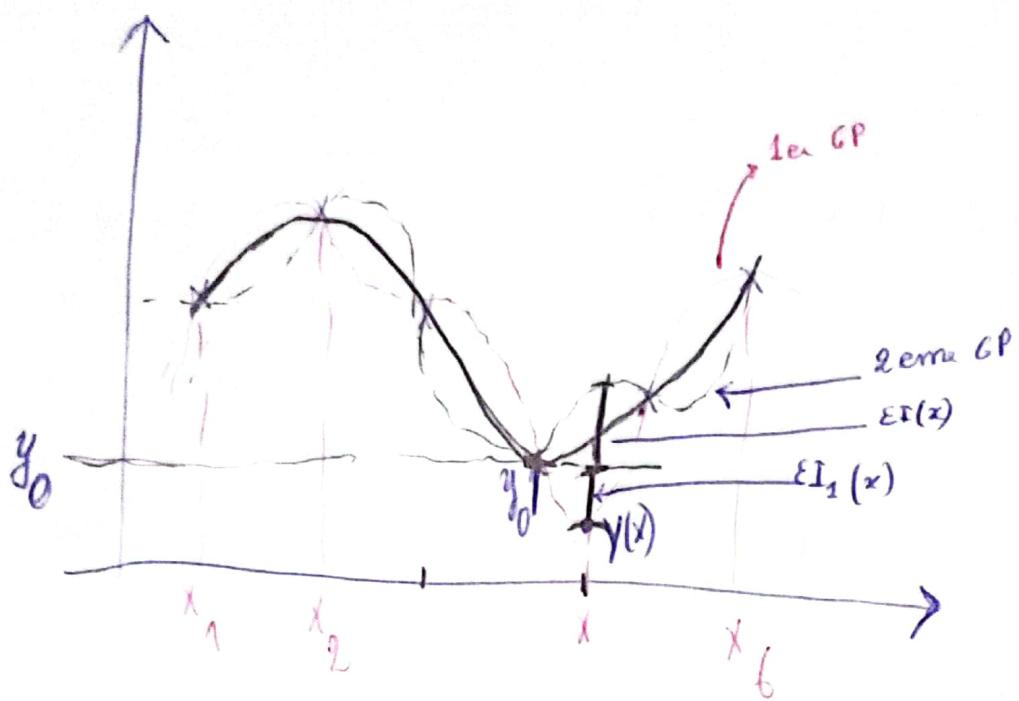
$$Y_2 = \{y_1, \dots, y_n, Y_c(x_{\text{new}})\}$$

$$\hat{\mu}_{\min 2} = \min(\tilde{Y}_2)$$

$$\hat{\mu}_{\min 2} \approx \hat{Y}_2$$

$$Y_c(x) = \{Y(x) \mid Y(x) = \tilde{Y}_2, x \in X\}$$

$$\{(P_{\min} - Y_c(x))_+, x \in X\}$$



on calcule EI pour chaque

on prend  $x$  qui maximise le critère d'amélioration  
pour l'ajouter ensuite à l'ensemble

$$x = \operatorname{argmax} EI(x)$$

Exercice 17 : calcul du critère EI

$$EI(x) = \mathbb{E} \left( (y_0 - y(x))_+ \mid Y(x_i) = y_i + \epsilon \mathcal{N}(0, \sigma^2) \right)$$

$\min(y_1, \dots, y_n)$

avec  $Y(x) \sim \mathcal{GP}(0, R)$

$$\text{Mq } EI(x) = \Delta_c(x) (z_0 \phi(z_0) + \phi(z_0))$$

avec  $\phi$  : densité de la  $N(0, 1)$

$\phi$  cdf de la loi  $N(0, 1)$

$$z_0 = \frac{y_0 - m_c(x)}{\sigma_c(x)}$$

La loi de  $Y(x) \mid Y(x_i) = y_i + \epsilon \mathcal{N}(0, \sigma^2)$  est une loi

$$N(m_c(x), \Delta_c^2(x))$$

$$EI(x) = \int_{\mathbb{R}} (y_0 - y)_+^2 \cdot \underset{\substack{\uparrow \\ \text{valeur} \\ \text{de } y(x)}}{\mathbb{P}}(Y(x) \mid Y(x_i) = y_i) \cdot dy$$

-  $\frac{1}{2} \frac{(y - m_c(x))^2}{\Delta_c^2(x)}$

$$= \int_{\mathbb{R}} (y_0 - y)_+ \cdot \frac{1}{\Delta_c^2(x) \sqrt{2\pi}} e^{-\frac{(y - m_c(x))^2}{2\Delta_c^2(x)}} \cdot dy$$

$$= \int_{\mathbb{R}} (y_0 - y)_+ \cdot \frac{1}{\Delta_c^2(x) \sqrt{2\pi}} e^{-\frac{(y - m_c(x))^2}{2\Delta_c^2(x)}} \cdot dy$$

$$= \int_{\frac{y_0 - m_c(x)}{\Delta_c(x)}}^{+\infty} \frac{1}{\Delta_c(x) \sqrt{2\pi}} e^{-\frac{u^2}{2}} du$$

$y > y_0$

$$EI(x) = 0$$

$$\text{si } y < y_0 \quad (y_0 - y)_+ = y_0 - y = -\frac{1}{2} \left( \frac{y - m_c(x)}{\Delta_c(x)} \right)^2$$

$$EI(x) = \int_{-\infty}^{y_0} (y_0 - y) \cdot \frac{1}{\sqrt{2\pi} \Delta_c(x)} e^{-\frac{(y - m_c(x))^2}{2\Delta_c^2(x)}} dy$$

$$u = \frac{y - m_c(x)}{\Delta_c(x)}$$

$$EI(x) = \int_{-\infty}^{\frac{y_0 - m_c(x)}{\Delta_c(x)}} (y_0 - u \cdot \Delta_c(x) - m_c(x)) \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du$$

$$z_0 = \frac{y_0 - m_c(x)}{\Delta_c(x)}$$

$$EI(x) = \int_{-\infty}^{z_0} (z_0 - u \cdot \Delta_c(x) - m_c(x)) \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du$$

$$= \Delta_c(x) \cdot \left[ \int_{-\infty}^{z_0} \frac{z_0}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du - \int_{-\infty}^{z_0} \frac{u \cdot \Delta_c(x)}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du \right]$$

$$= \Delta_c(x) \left[ z_0 \Phi(z_0) + \int_{-\infty}^{z_0} \frac{(-u)}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du \right]$$

$$\Phi = \Delta_c(x) \left[ z_0 \Phi(z_0) + \left[ \frac{e^{-\frac{u^2}{2}}}{\sqrt{2\pi}} \right]_{-\infty}^{z_0} \right]$$

$$= \Delta_c(x) = \int_{-\infty}^{z_0} \Phi(z_0) + \left[ \frac{e^{-\frac{u^2}{2}}}{\sqrt{2\pi}} \right]_{-\infty}^{z_0}$$

$$\frac{m_c(x)}{\sqrt{2\pi}}$$

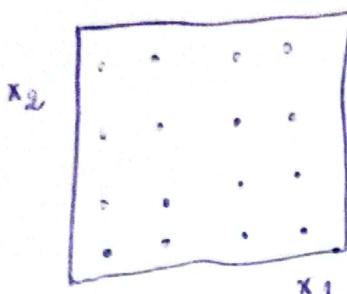
$$= \Delta_c(x) \left[ z_0 \Phi(z_0) + \phi(z_0) \right]$$

Design of computer experiments

Ran  
Exa  
Seco  
men  
Vau  
Statisti  
de  
metri  
21  
Cours

Exercice 16

1)  $P_{\text{sim}} : [0,1]^2 \rightarrow \mathbb{R}$  dépend de la  
seule variable  $x_3$   
 $\Rightarrow$  de cette une au moins



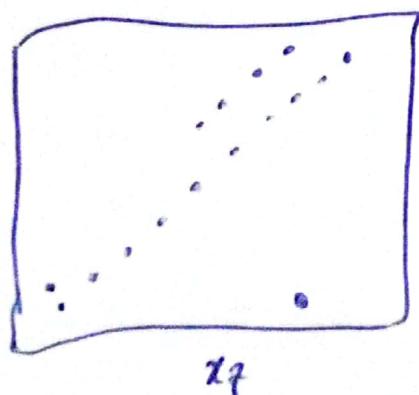
$$P_{\text{sim}}(1,0) = P_{\text{sim}}(1,1)$$

$$P_{\text{sim}}(1,\frac{1}{3}) = P_{\text{sim}}(1,\frac{2}{3})$$

comme  $x_2$  est inutile  
et  $x_3$  prend seulement 4 valeurs différentes  
parmi les 16 qui sont disponibles  
 $\Rightarrow 75\%$  de l'info est perdue

Pour résoudre ce problème, on utilise un hypercube  
Palin: toutes les valeurs de  $x_3$  (et 2e APA) seront  
différentes  
 $\Rightarrow$  pas de perte d'information

i)



Le plan n'est pas adapté en particulier si  
 $P_{\text{sim}}(x_1, x_2) \rightarrow x_8 = g(x_1, x_2)$

Car dans le plan  $(x_1, x_2)$  on n'exploré pas  
bien l'espace.

Si  $f(x_1, x_2, \dots, x_8) = g(x_1 - x_2)$   
et n'y a que 3 valeurs de  $x_1 - x_2$   
 $\Rightarrow$  on perd  $\frac{13}{16}$  d'info

## Analyse de sensibilité

Exercice 2.9 : ANOVA en dimension 2

$X_1, X_2$  va indépendantes

$X_i$  de loi  $\mathcal{V}_i$      $i = 1 \text{ à } 2$

$f \in L^2(\mathcal{V})$      $\mathcal{V} = \mathcal{V}_1 \otimes \mathcal{V}_2$

me want to prove the Seiel Heffding

$$Y = f(X_1, X_2) = f_0 + f_1(X_1) + f_2(X_2) + f_{1,2}(X_1, X_2)$$

$$\text{avec } \mathbb{E}(f_i(X_i) | X_j) = 0 \text{ si } j \neq i$$

$$\Rightarrow \text{si } I = \{1\} \quad \mathbb{E}(f_1(X_1) | X_2) = \mathbb{E}(f_1(X_1)) = 0$$

$$J = \emptyset$$

$$\text{si } I = \{2\} \quad \mathbb{E}[f_2(X_2)] = 0$$

$$J = \emptyset$$

$$\text{si } I = \{1, 2\}$$

$$\mathbb{E}[f_{1,2}(X_1, X_2)] = 0$$

$$\begin{array}{c} \xrightarrow{\phi} \\ \left\{ \begin{array}{l} \{1\} \\ \{2\} \end{array} \right. \end{array} \quad \mathbb{E}[f_{3,2}(X_1, X_2) | X_1] = 0$$

$$\mathbb{E}[f_{3,2}(X_1, X_2) | X_2] = 0$$

Si une telle décomposition existe alors elle est

$$\text{donnée par } f_0 = \mathbb{E}(f(X))$$

$$i=1,2 \quad f_i(X_i) = \mathbb{E}(f(X) | X_i) - f_0$$

$$f_{1,2}(X_1, X_2) = \mathbb{E}(f(X) | X_1, X_2)$$

$$- f_1(X_1) - f_2(X_2) - f_0$$

$$\boxed{f(X_1, X_2) = f_0 + f_1(X_1) + f_2(X_2) + f_{1,2}(X_1, X_2)}$$

$$\mathbb{E}[f(X_1, X_2)] = f_0 + \mathbb{E}[f_1(X_1)] + \mathbb{E}[f_2(X_2)] + \mathbb{E}[f_{1,2}(X_1, X_2)]$$

$$X = (X_1, X_2)$$

d'après les hypothèses

$$\mathbb{E}[f_1(X_1)] = 0 \quad \mathbb{E}[f_2(X_2)] = 0$$

$$\text{ainsi } \boxed{\mathbb{E}[f(X)] = f_0}$$

$$\begin{aligned} \mathbb{E}(f(X_1, X_2) | X_1) &= f_0 + \mathbb{E}[f_1(X_1) | X_1] + \mathbb{E}[f_2(X_2) | X_1] \\ &\quad + \mathbb{E}[f_{1,2}(X_1, X_2) | X_1] \\ &= 0 \text{ par hypothèse} \end{aligned}$$

on connaît déjà  $X_1$

$$\Rightarrow \mathbb{E}[f_1(X_1) | X_1] = f_1(X_1)$$

$$\mathbb{E}[f_2(X_2) | X_1] = \mathbb{E}[f_2(X_2)] \cdot \underbrace{B}_{\text{car } X_1 \perp \!\!\! \perp X_2} = 0$$

Ainsi

$$\boxed{\mathbb{E}[f(X_1, X_2) | X_1] = f_0 + f_1(X_1)}$$

$$\boxed{f_1(X_1) = \mathbb{E}[f(X_1 | X_2)] - f_0}$$

$$\begin{aligned} \mathbb{E}[B(x_1, x_2) | x_1, x_2] &= \mathbb{E}[b_0 | x_1, x_2] + \mathbb{E}[b_1(x_1) | x_1, x_2] + \mathbb{E}[b_2(x_2) | x_1, x_2] + \mathbb{E}[b_{1,2}(x_1, x_2) | x_1, x_2] \\ &= b_0 + b_1(x_1) + b_2(x_2) + b_{1,2}(x_1, x_2) \end{aligned}$$

$$b_{1,2}(x_1, x_2) = \mathbb{E}[B(x_1, x_2) | x_1, x_2] - b_0 - b_1(x_1) - b_2(x_2)$$

~~Si les hypothèses sont vérifiées~~

$$\begin{aligned} b_{1,2}(x_1, x_2) &= \mathbb{E}[B(x) | x_1, x_2] - b_1(x_1) - b_2(x_2) - b_0 \\ &= \mathbb{E}[B(x) | x_1, x_2] - \mathbb{E}[b(x) | x_1] \overset{b_0}{=} \mathbb{E}[B(x) | x_2] \overset{b_0 - b_2(x_2)}{=} \\ &= \mathbb{E}[B(x) | x_1, x_2] - \mathbb{E}[B(x) | x_1] - \mathbb{E}[B(x) | x_2] + \mathbb{E}[B(x)] \end{aligned}$$

~~Si les hypothèses sont vérifiées~~

$$b_1(x_1) = \mathbb{E}[B(x) | x_1] - b_0$$

$$\begin{aligned} \mathbb{E}[b_1(x_1)] &= \mathbb{E}[\mathbb{E}(B(x) | x_1)] - \mathbb{E}[b_0] \\ &= \mathbb{E}[B(x)] - b_0 \end{aligned}$$

$$\text{car } \mathbb{E}[\mathbb{E}[Y | X]] = \mathbb{E}[Y]$$

$$= b_0 - b_0$$

$$= 0$$

de même

$$\mathbb{E}[b_2(x_2)] = 0$$

$$\begin{aligned} \mathbb{E}[b_{1,2}(x_1, x_2) | x_1] &= \mathbb{E}\left[\overbrace{\mathbb{E}[B(x) | x_1, x_2]}^{= B(x)} | x_1\right] \\ &\quad - \mathbb{E}[b_1(x_1) | x_1] - \mathbb{E}[b_2(x_2) | x_1] - \mathbb{E}[b_0 | x_1] \end{aligned}$$

$$\begin{aligned} &\stackrel{\text{car } \mathbb{E}[B(x) | x_1] = \mathbb{E}[b_1(x_1) | x_1] = \mathbb{E}[b_2(x_2) | x_1]}{=} 0 \\ &= 0 \end{aligned}$$

$$2) P_{3,2}(x_3, x_2) = \mathbb{E}[f(x)|x_3, x_2] - \mathbb{E}[\mathbb{E}[f(x)|x_3]] - \mathbb{E}[\mathbb{E}[\mathbb{E}[f(x)|x_2]] + \mathbb{E}[f(x)]]$$

$$= \mathbb{E}[f(x)|x_3, x_2] - \mathbb{E}[f(x)|x_3] + b_0 - \mathbb{E}[f(x)|x_2] + b_0 - b_0$$

$$= \mathbb{E}[f(x)|x_3, x_2] - \mathbb{E}[f(x)|x_3] - \mathbb{E}[f(x)|x_2] + \mathbb{E}[f(x)]$$

$$3) I = \{1\} \quad I' = \emptyset$$

$$\mathbb{E}[P_I(x_I) \cdot P_{I'}(x_{I'})] = 0$$

$$I = \{1\} \quad I' = \{2\}$$

$$\mathbb{E}[P_1(x_1) \cdot P_2(x_2)] = \mathbb{E}[P_1(x_1)] \cdot \mathbb{E}[P_2(x_2)]$$

=

$$\left| \begin{array}{l} I = \{1\} \quad I' = \{2\} \\ \mathbb{E}[P_1(x_1) \cdot P_{3,2}(x_3, x_2)] \\ = \mathbb{E}\left[ \mathbb{E}\left[ P_1(x_1) \cdot P_{3,2}(x_3, x_2) \mid x_1 \right] \right] \\ \downarrow \\ \text{dienkt} \\ \text{determinante} \\ = \mathbb{E}[P_1(x_1) \cdot \underbrace{\mathbb{E}[P_{3,2}(x_3, x_2) \mid x_1]}_{0 \text{ für Hypothese}}] \\ = 0 \end{array} \right.$$

$$h) f(x_1, x_2) = x_1 \quad x_1 \text{ is centered}$$

$$\begin{aligned} f(x_1, x_2) &= 0 + x_1 + 0 + 0 \\ &= 0 + \underbrace{0}_{f_0} + \underbrace{0}_{f_1(x_1)} + \underbrace{x_2}_{f_2(x_2)} \rightarrow f_{1,2}(x_1, x_2) \end{aligned}$$

in der zweiten chw. varie

$$\mathbb{E}[P_{3,2}(x_1, x_2) \mid x_1] = \mathbb{E}[x_1 \mid x_1] = x_1 + 0 \quad \text{abrechnen}$$

Decomposition de Sobel - Hoeffding

$X_1, \dots, X_d$  va indépendantes

$$B(X_1, \dots, X_d) = B_0 + B_1(X_1) + \dots + B_d(X_d) + B_{1,2}^*(X_1, X_2) + \dots + B_{1,2,\dots,d}(X_1, X_2, \dots, X_d)$$

On a existence et unicité d'une décomposition

$$B(X) = (X_1, \dots, X_d)$$

$$B(X) = B_0 + B_I(X) \sum_{i=1}^d B_i(X_i) + \sum_{i < j} B_{ij}(X_i, X_j) + \dots + B_{1,2,\dots,d}(X_1, X_2, \dots, X_d)$$

$$\text{avec } \mathbb{E}[B_I(X_i) | X_j] = 0 \text{ si } j \neq i$$

On a

$$B_0 = \mathbb{E}[B(X)]$$

$$B_i(X_i) = \mathbb{E}[B(X) | X_i] - B_0 : \text{effet principal}$$

$$B_{ij}(X_i, X_j) = \mathbb{E}[B(X) | X_i, X_j] - B_i(X_i) - B_j(X_j) - B_0 : \text{interaction d'ordre 2}$$

$$B_{ij}(X_i, X_j) = \mathbb{E}[B(X) | X_i, X_j] - \mathbb{E}[B(X) | X_i] - \mathbb{E}[B(X) | X_j] + B_0$$

$$B_I(X_I) = \mathbb{E}[B(X) | X_I] - \sum_{j \in I} B_{Ij}(X_j) \rightarrow \text{Recursion Formula}$$

$$= \sum_{j \in I} (-1)^{|I| - |Ij|} \mathbb{E}[B(X) | X_j] \rightarrow \text{inclusion - exclusion}$$

En outre, tous les termes sont centré et orthogonaux

$$\text{si } I \neq J \quad \mathbb{E}[B_I(X_I) B_J(X_J)] = 0 \iff \text{cov}(B_I(X_I), B_J(X_J)) = 0$$

## Décomposition de la Variance (ANOVA)

analysis of variance

$$\text{Var}(f(x)) = \sum_{i=1}^d \text{Var} f_i(x_i) + \sum_{i < j} \text{Var}(P_{ij}(x_i, x_j)) + \dots + \text{Var}(P_{s,d}(x_1, \dots, x_d))$$

On mesure l'influence de  $x_i$  sur  $y = f(x)$  par

$$s_i = \frac{\text{Var}(P_i(x_i))}{\text{Var}(f(x))}$$

% de variance expliquée par  $x_i$

→ Indice de Sobel  $\in [0, 1]$

$$s_i^{\text{tot}} = \frac{\sum_{I \subseteq \{s, d\}, i \in I} \text{Var}(P_I(x_i))}{\text{Var}(f(x))}$$

$$= \sum_{i \in I} \frac{\text{Var} P_I(x_i)}{\text{Var}(f(x))} : \begin{array}{l} \text{indice de Sobel total} \\ \% \text{ de variance expliquée par } x_i \text{ et toutes ses interactions} \end{array}$$

$$s_I = \frac{\text{Var}(P_I(x_i))}{\text{Var}(f(x))} : \% \text{ de variance expliquée par le terme } P_I(x_i)$$

$$\text{Rq: } \sum_{I \subseteq \{s, \dots, d\}} s_I = 1$$

### Exercice 21 : Estimation fonction

$$\Delta = [-\pi, \pi]^3 \quad x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

$$f(x) = \sin(x_1) + A \sin^2(x_2) + B x_3^4 \sin(x_1) \quad \text{avec } A=7 \quad B=0.1$$

$\hat{f}(x) = \sin(x_1) + A \sin^2(x_2) + B x_3^4 \sin(x_1)$  est l'estimation de Sobel Hoffding de  $f(x_1, x_2, x_3)$

③ Calculer la décomposition de Sobel Hoffding de  $\hat{f}(x_1, x_2, x_3)$

avec  $x_1, x_2, x_3$  uniformes sur  $[-\pi, \pi]$  et indépendantes

Calculer les indices de Sobel

$$\text{On donne } a = \int_{-\pi}^{\pi} \sin^2(u) \cdot \frac{du}{2\pi} = \frac{1}{2}$$

$$b = \int_{-\pi}^{\pi} u^4 \cdot \frac{du}{2\pi} = \frac{\pi^4}{5}$$

$$\mathbb{E}[x_1] = \mathbb{E}[x_2] = \mathbb{E}[x_3] = 0$$

$$\hat{f}_0 = \mathbb{E}[\hat{f}(x)] = \mathbb{E}[\sin(x_1)] + A \cdot \mathbb{E}[\sin^2(x_2)] + B \cdot \mathbb{E}[x_3^4 \sin(x_1)]$$

$$\begin{aligned} \mathbb{E}[\sin(x_1)] &= \sqrt{\int_{-\pi}^{\pi} \sin^2(x) \cdot \frac{dx}{2\pi}} \int_{-\pi}^{\pi} \sin(x) \cdot \frac{1}{2\pi} \cdot dx \\ &= \sqrt{\int_{-\pi}^{\pi} -\cos(x) \cdot x \cdot \frac{dx}{2\pi}} = 0 \end{aligned}$$

$$\mathbb{E}[\sin^2(x_2)] = \int_{-\pi}^{\pi} \sin^2(x) \cdot \frac{1}{2\pi} \cdot dx = \frac{1}{2}$$

$$\mathbb{E}[x_3^4 \sin(x_1)] = \mathbb{E}[x_3^4] \mathbb{E}[\sin(x_1)] \quad \text{par indép}$$

$$\begin{aligned} \mathbb{E}[x_3^4] &= \int_{-\pi}^{\pi} x_3^4 \cdot \frac{1}{2\pi} \cdot dx_3 = 0 \end{aligned}$$

$$\hat{f}_0 = \frac{A}{2}$$

$$\begin{aligned} b_1(x_1) &= \mathbb{E}\{b(x) | x_1\} = \mathbb{E}\{\sin(x_1) | x_1\} + A \mathbb{E}\{\sin^2(x_2) | x_1\} + B \mathbb{E}\{x_3^4 \sin(x_3) | x_1\} - 80 \\ &= \sin(x_1) + A \mathbb{E}\{\sin^2(x_2)\} + B \sin(x_3) \cdot \mathbb{E}\{x_3^4\} - 80 \\ &= \sin(x_1) + A \mathbb{E}\{\sin^2(x_2)\} + B \sin(x_3) \cdot \mathbb{E}\{x_3^4\} - 80 \end{aligned}$$

$\downarrow$   
 $\cos x_1 \perp\!\!\!\perp x_2$

$$\begin{aligned} &= \sin(x_1) + \frac{A}{2} + \frac{B \cdot \frac{\pi^4}{5}}{5} \sin(x_3) - \frac{A}{2} \\ &= \sin(x_1) \left( 1 + B \cdot \frac{\pi^4}{5} \right) \end{aligned}$$

$$\begin{aligned} b_2(x_2) &= \mathbb{E}\{b(x) | x_2\} = \mathbb{E}\{\sin(x_1)\} + A \sin^2(x_2) + B \mathbb{E}\{x_3^4 \sin(x_3)\} - 80 \\ &= 0 + A \sin^2(x_2) - \frac{A}{2} + B \mathbb{E}\{\sin^2(x_3)\} + B x_3^4 \cdot \mathbb{E}\{\sin(x_3)\} - 80 \end{aligned}$$

$$\begin{aligned} b_3(x_3) &= \mathbb{E}\{b(x) | x_3\} = \mathbb{E}\{\sin(x_1)\} + A \cdot \mathbb{E}\{\sin^2(x_2)\} + B x_3^4 \sin(x_3) - b_1(x_3) - b_2(x_3) - b_3(x_3) \\ &= 0 + \frac{A}{2} + 0 - \frac{A}{2} \\ &= 0 \end{aligned}$$

$$\begin{aligned} b_{1,3}(x_1, x_3) &= \mathbb{E}\{b(x) | x_1, x_3\} = \sin(x_1) + A \cdot \mathbb{E}\{\sin^2(x_2)\} + B x_3^4 \sin(x_3) - b_1(x_3) - b_2(x_3) - b_3(x_3) \\ &= \frac{\pi}{2} + \sin(x_1) \left( 1 + B x_3^4 \right) - \sin(x_1) \left( 1 + B \frac{\pi^4}{5} \right) - 0 - \frac{A}{2} \end{aligned}$$

$$\begin{aligned} b_{1,2}(x_1, x_2) &= \mathbb{E}\{b(x) | x_1, x_2\} = \sin(x_1) + A \sin(x_2) + B \sin(x_3) \cdot \mathbb{E}\{x_3^4\} \\ &= \sin(x_1) + A \sin(x_2) + B x_3^4 - B \cdot \frac{\pi^4}{5} \end{aligned}$$

$$b_1(x_1) + b_2(x_2) + b_3(x_3) + b_{1,3}(x_1, x_3) = b(x)$$

On peut alors développer et déduire que

$$\Rightarrow b_{1,2}(x_1, x_2) = 0 \quad b_{2,3}(x_2, x_3) = 0 \quad \text{et} \quad b_{1,2,3}(x_1, x_2, x_3) = 0$$

## Calcul des indicateurs de Sobel

$$S_i = \frac{D_i}{D} \quad D_i = \text{Var}(f_i(x_i))$$

$$S_I = \frac{D_I}{D} \quad D_I = \text{Var}(f_I(x_I))$$

Astuce 1:  $\text{SE}\left[f_I(x_I)\right] = 0 \Rightarrow D_I = \text{IE}\left[f_I^2(x_I)\right]$

Astuce 2:  $D = \sum_I D_I$

$$\begin{aligned} D_1 &= \text{IE}\left[f_1^2(x_1)\right] = \text{IE}\left[\sin^2(x_1) \cdot \left(1 + B \frac{\pi^4}{5}\right)^2\right] \\ &= \left(1 + B \frac{\pi^4}{5}\right)^2 \cdot \int_{-\pi}^{\pi} \sin^2(x_1) \cdot \frac{1}{2\pi} dx_1 \approx \frac{1}{2} \\ &= \frac{1}{2} \left(1 + B \frac{\pi^4}{5}\right)^2 \end{aligned}$$

$$D_2 = \text{IE}\left[f_2^2\right] = \frac{A^2}{4}$$

$$\begin{aligned} D_2 &= \text{IE}\left[f_2^2\right] = \text{IE}\left[A^2 \sin^4(x_2)\right] = \text{IE}\left[A^2 \cdot \sin^2(x_2)\right] + \text{IE}\left[\frac{A^2}{2}\right] \\ &= \frac{1}{2\pi} A^2 \cdot \frac{3\pi}{4} - \frac{A^2}{2} + \frac{A^2}{2} \\ &\approx \frac{3A^2}{8} \end{aligned}$$

$$D_3 = \text{IE}\left[f_3^2(x_3)\right] = 0$$

$$D_{1,2} = 0$$

$$D_{2,3} = 0$$

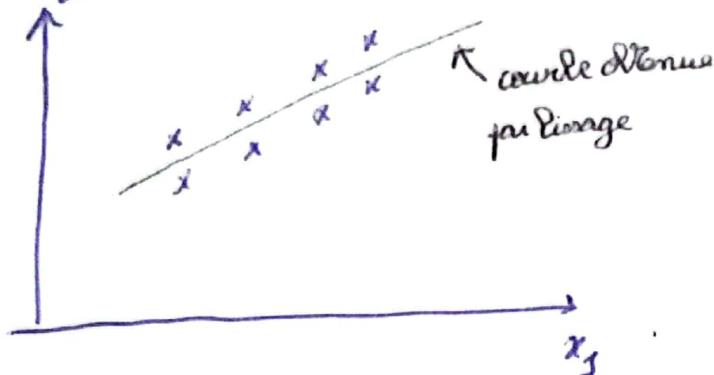
$$D_{3,1} = B^2 \left( \text{IE}(x_3^2) - 2H \text{IE}(x_3) + \frac{H^2}{5} \right) \cdot \frac{A}{2}$$

$$= B^2 \cdot \left( \frac{H^2}{9} - \frac{\pi^4}{5} \right) \frac{A}{2}$$

Vérification numérique des résultats : Estimation de  $x_1 \rightarrow \mathbb{E}\{f(x) | X_1 = x_1\}$

idée ① : simuler  $x^{(1)}, \dots, x^{(n)}$  selon la loi de  $X$   
② représenter  $f(x^{(i)})$  contre  $x_1^{(i)}$  et estimer  
la courbe moyenne ~~de~~

$$f(x) = f(x_1, x_2, x_3)$$



Exercice

Courbe 1 : On remarque que la tendance donne

$f_1(x_1)$  est sous forme de sinus (pente =  $\pi$ )

Courbe 2 : On remarque la tendance donne

$f_2(x_2)$  est sous forme de  $\sin^2$  (pente =  $\pi$ )

Courbe 3 : On remarque que  $f_3(x_3) = 0$

<u>Random Process</u> : family of RV $\{Y(x)\} = Y$	<u>Gaussian Process approach</u>
<u>trajectory</u> : $x \mapsto Y(x) (w)$	$U = \begin{pmatrix} V \\ W \end{pmatrix}$
<u>Second order RP</u> : when $Y(x) \in L^2(\Omega)$	$V = \begin{pmatrix} y(x) \\ y(x_1) \\ \vdots \\ y(x_n) \end{pmatrix}, W = \begin{pmatrix} y(x_1) \\ \vdots \\ y(x_n) \end{pmatrix}$
<u>mean</u> : $x \mapsto E[Y(x)]$ ; $R(x, x') =$	<u>Varian vector gaussian</u>
$R(x, x') = R(x, x) - \text{cov}(Y(x), Y(x'))$	$U \sim N \left( \begin{pmatrix} m(x) \\ m(x_1) \\ \vdots \\ m(x_n) \end{pmatrix}, \begin{pmatrix} R(x, x) & R(x, X) \\ R(X, x) & R(X, X) \end{pmatrix} \right)$
<u>Stationarity</u> : the law $(Y(x_1+k), \dots, Y(x_n+k))$ does not depend on $k$	<u>independance of <math>y(x)</math> and <math>y(x')</math></u> : $R(x, x') = 0$
<u>strict stationarity</u> : $E[Y(x)] = m$ (constant)	$m_i(x) = E[V   W = w] = m(x) + R(x, x) R(X, X)^{-1} (y - m(x))$
$R(x, x') = c(x-x')$ : depends only on $x-x'$	$\text{Var}(V   W = w) = R(x, x) - R(x, X) R(X, X)^{-1} R(X, x)$
<u>Gaussian Process</u> : if $\{Y(x_1), \dots, Y(x_n)\}$ is a Gaussian vector $\Rightarrow Y \sim GP(m, R)$	<u>enveloppe de confiance</u>
<u>stationary <math>\Leftrightarrow</math> weakly stationary</u>	$Z \sim N(P_Z, \epsilon_Z^2)$
<u>independance of <math>y(x)</math> and <math>y(x')</math></u> : $R(x, x') = 0$	$P_Z \pm 2\epsilon_Z \approx 95\%$
<u>linearity of CP</u>	$P_Z \pm 2\epsilon_Z \approx 99.7\%$
a) $y \sim CP$ and $L$ : Precomposition $\Rightarrow Ly \sim CP$	$P \{ Z \in [P_Z - 2\epsilon_Z, P_Z + 2\epsilon_Z] \} = 99.7\%$
$dy = AP(dx, P)$ $\Rightarrow Ly \sim CP(0, R_L)$	$\epsilon_{Z, 99.7\%} = 3\epsilon_Z$
$R_L(x, t) = L_x L_t^{-1} R(x, t)$	
b) $y \sim CP(0, R)$ $\Rightarrow y' \sim CP(0, R')$	
$R' = R + \frac{\partial^2 R}{\partial x^2}(x, t)$	
<u>matrice de covariance</u>	
$\text{cov} \begin{pmatrix} z(x_1) \\ z(x_2) \\ z(x_3) \end{pmatrix} = \begin{pmatrix} \text{var}(z(x_1)) & \text{cov}(z(x_1), z(x_2)) & \text{cov}(z(x_1), z(x_3)) \\ \text{cov}(z(x_2), z(x_1)) & \text{var}(z(x_2)) & \text{cov}(z(x_2), z(x_3)) \\ \text{cov}(z(x_3), z(x_1)) & \text{cov}(z(x_3), z(x_2)) & \text{var}(z(x_3)) \end{pmatrix}$	
$= R(x, x)$	
<u>My <math>y</math> est un CP</u> $\Leftrightarrow$ prendre une comb linéaire et $ly$ c'est aussi une loi normale	
<u>examples of Kernels of 1-D CP</u>	<u>Observations bruitées</u>
1/ cosine: $R(x, x') = \cos(\pi(x-x'))$	$V = (y(x)) \quad W = \begin{pmatrix} y(x) + \epsilon_1 \\ \vdots \\ y(x_n) + \epsilon_n \end{pmatrix}$
2/ sin: $R(x, x') = \frac{\sin(\pi(x-x'))}{\pi(x-x')}$	$E[U] = \begin{pmatrix} m(x) \\ m(x_1) \\ \vdots \\ m(x_n) \end{pmatrix} \quad \epsilon_i \sim N(0, \epsilon_i^2)$
3/ squared exp: $R(x, x') = \exp(-\frac{1}{2} \frac{(x-x')^2}{\sigma^2})$	$\text{cov}(V) = R(x, x) + \Delta$
4/ exp: $R(x, x') = \exp(-\frac{ x-x' }{\sigma})$	$\Delta = \begin{pmatrix} \epsilon_1^2 & (0) & & \\ (0) & \ddots & \ddots & \\ & & \ddots & \epsilon_n^2 \end{pmatrix}$
5/ matern 3/2: $(1 + \sqrt{3} \frac{ x-x' }{\sigma}) \exp(-\sqrt{3} \frac{ x-x' }{\sigma})$	$\text{cov}(U) = \begin{pmatrix} R(x, x) & R(x, X) \\ R(X, x) & R(X, X) + \Delta \end{pmatrix}$
6/ matern 5/2: $(1 + \sqrt{6} \frac{ x-x' }{\sigma} + \frac{1}{2} \frac{(x-x')^2}{\sigma^2}) \exp(-\sqrt{6} \frac{ x-x' }{\sigma})$	
<u>operations on kernels</u>	
$R$ Kernel $\rightarrow$ c.R Kernel	
$R_1, R_2$ kernels $\rightarrow R_1 + R_2$ kernel	
$R_1 \otimes R_2$ Kernel (on $(x_1, x_2)$ )	
$R_1 R_2$ Kernel	
$R_1 @ R_2$ Kernel	
$R$ Kernel on $\mathbb{X}^2 \Rightarrow R_f(x, x') = R(P_1 x, P_1 x')$	
$l: U \rightarrow X$	
<u>How to obtain kernels on d-dimensional space</u>	
The tensor product is usually used to define kernels on d-dimensional spaces from 1-dimensional space	
$R(x, x) = e^{-\ x-x'\ ^2}$	

## Bayesian optimization

is a powerful technique for optimizing time consuming functions.

The Bayesian principle behind it is to build a probabilistic model on the function and using it to guide the search for the best solution:

- it involves
  - 1/ initial sampling of the function
  - 2/ create a surrogate model to estimate the function's behavior, typically using gaussian process (thanks to their flexibility in modeling complex functions and uncertainty : capture mean and variance of the function)
  - 3/ using an acquisition function to determine the next point to evaluate. It balances exploration and exploitation (using unexplored algorithm regions and sampling in regions with high predicted values) Ex: Expected improvement
- 4/ evaluate the expensive objective function at the selected point
- 5/ updating the surrogate model with the new data
- 6/ repeat 3, 4, 5 iteratively
- 7/ stop the algorithm based on a stopping criterion
- 8/ return the best solution

gradient check instead LOE ( $x_1, \dots, x_n$ ,  $y = \{y_1, \dots, y_n\}$ )

$f(x)$  is in range nb\_iterations

build surrogate model: GP model with  $\gamma$  and  $\rho$

compute acquisition function:  $EI(x)$

find maximum of the criterion:  $\max_{x \in \mathcal{X}} EI(x)$

evaluate the objective function at this max

add it to the current function to form

update the LOE after the best solution

return

turn the parameters of a model  $\rightarrow$  apply LOE as a cost criterion over criterion

if one parameter is discrete and the squared exponential kernel?

the usual squared exponential kernel is based on distance

of the variable is ordinal (number) it can make sense

(distance between these levels)

if it is not ordinal, it is much less making sense.

there are specific kernels for this case.

in the ordinal case, such kernels account for non stationarities. The distance between levels 2 and 3 is not necessarily the same between levels 1 and 2 in making sense.

free hyperparameters: An affine in Hypercube

Latin design (LHD) using LHS. Latin Hypercube sampling uses the values  $x_1, \dots, x_n$  different different dimensions.

Re-sampling or undersampling.

determine the number of replications & dimensionality

An explorative approach

## LHD construction

is based on the idea of stratified sampling  
the proportion of points that belong to some interval are forced to equal the theoretical one

EGO: Efficient global optimization

criterion with noise: Expected improvement criterion

analyse des sensibilités

$$P_0 = \mathbb{E}[f(x)]$$

$$P_i(x_i) = \mathbb{E}[f(x)|x_i] - P_0$$

$$P_{i,j}(x_j)$$

$$P_{i,j}(x_j) = \mathbb{E}[f(x)|x_i, x_j] - P_i - P_j + P_0$$

$$P_I(x_I) = \mathbb{E}[f(x)|x_I] - \sum_{j \neq I} P_j(x_j)$$

$$= \sum_{j \neq I} (-1)^{|I|-|j|} \mathbb{E}[f(x)|x_j]$$

plus bennes sont courbes et allégories

$$S_i = \frac{\text{Var}(P_i(x_i))}{\text{Var}(f(x))}; \text{ under de telles}$$

~~$$S_i^T = \frac{\text{Var}(x_I f_I(x_I))}{\text{Var}(f(x))} \sum_{j \neq I} \frac{\text{Var}(P_j(x_j))}{\text{Var}(f(x))}$$~~

$$S_I = \frac{\text{Var}(P_I(x_I))}{\text{Var}(f(x))}$$

$$R_I \sum S_I = 1$$

$$\text{et } \mathbb{E}[P_I(x_I)] = 0 \Rightarrow D_I = \mathbb{E}[P_I^2(x_I)]$$

$$D = \sum_I D_I$$